Large-Scale Machine Learning (LSML)

О курсе

Лекции

1. Онлайн-обучение и линейные модели
2. Введение в Apache Spark
3. Рекомендательные системы
4. Градиентный бустинг для больших данных
5. Введение в TensorFlow
6. Нейросети для классификации картинок
7. Нейросети для классификации текстов
8. LSH для поиска похожих объектов
9. Кластеризация больших данных

python™

TensorFlow

Домашние задания

1. Рекомендательная система на Apache Spark

2. Реализация градиентного бустинга над решающими деревьями на Apache Spark

3. Аннотирование картинок на TensorFlow

Домашние задания

- Выполняются на виртуальных машинах в облаке Azure

- У каждого студента:
  - Свой логин/пароль в Azure, будут выданы позже
  - Свой Hadoop-кластер с Apache Spark
  - Своя машина с GPU и TensorFlow
  - Дается 2 недели использования ресурсов на каждое задание

Формула оценки

- Результирующая оценка по дисциплине рассчитывается по формуле

$$О\_итог=\mathbf{0.7}\ О\_накопл + \mathbf{0.3}\ О\_экз$$

- Накопленная оценка рассчитывается по формуле

$$О\_накопл=\mathbf{0.3}\ О\_дз1 + \mathbf{0.3}\ О\_дз2 + \mathbf{0.4}\ О\_дз3$$

- Накопленная и итоговая оценки округляются арифметически.

Экзамен

- Устный экзамен
- Задачи на листочке
- Лучше хорошо делать ДЗ и получить автомат (О_накопл > порога)

LSML #1

Онлайн-обучение и линейные модели

Онлайн-обучение

Онлайн-обучение – данные поступают последовательно, улучшаем модель после каждого нового примера

Когда используется:

- Невозможно обучаться на всей выборке
- Вся выборка не помещается в память
- Нужно быстро адаптироваться к новым зависимостям в данных

https://en.wikipedia.org/wiki/Online_machine_learning#Statistical_learning_models

На примере линейной регрессии

- Обучение на всей выборке:

$$w^* = (X^T X)^{-1} X^T Y$$

- Можно обновлять веса рекурсивно:

$$w_0 = 0 \in \mathbb{R}^d \qquad \Gamma_i = \Gamma_{i-1} - \frac{\Gamma_{i-1} x_i x_i^T \Gamma_{i-1}}{1 + x_i^T \Gamma_{i-1} x_i}$$

$$\Gamma_0 = I \in \mathbb{R}^{d \times d} \qquad w_i = w_{i-1} - \Gamma_i x_i (x_i^T w_{i-1} - y_i)$$

- Стохастический градиентный спуск (SGD):

Похожи

$$w_i = w_{i-1} - \gamma_i x_i (x_i^T w_{i-1} - y_i)$$

Vowpal Wabbit (VW)

- Открытая реализация алгоритмов онлайн-обучения
- Не только линейные модели (парные взаимодействия, нейросети)
- Много функций потерь
- Обычная строка текста – это валидное описание объекта. Применяет хэширование признаков.
  - 1 | The dog ate my homework
- Эффективно масштабируется на 1000 машин при помощи AllReduce.
- Может работать в режиме с обратной связью (Contextual Bandit)
- Может работать в режиме активного обучения
- …

Хэширование признаков

- Требуется one-hot кодирование признаков
  - Категориальные признаки
  - Слова текста в модели мешка слов

- Храним “word” → index
  - Словарь должен быть общим для всех машин
  - Может не поместиться в RAM

- Считаем “word” → hash(“word”)
  - Большое число корзинок хэш-функции (~2^{24}), качество растет по log(hash bits)
  - Значительно быстрее, не занимает памяти и легко распараллеливается

http://www.machinelearning.org/archive/icml2009/papers/407.pdf

Хэширование в детекции спама

- 0.4 млн пользователей, 3.2 млн писем, 40 млн слов
- 16 трлн пар (пользователь, слово) – поможет только хэширование

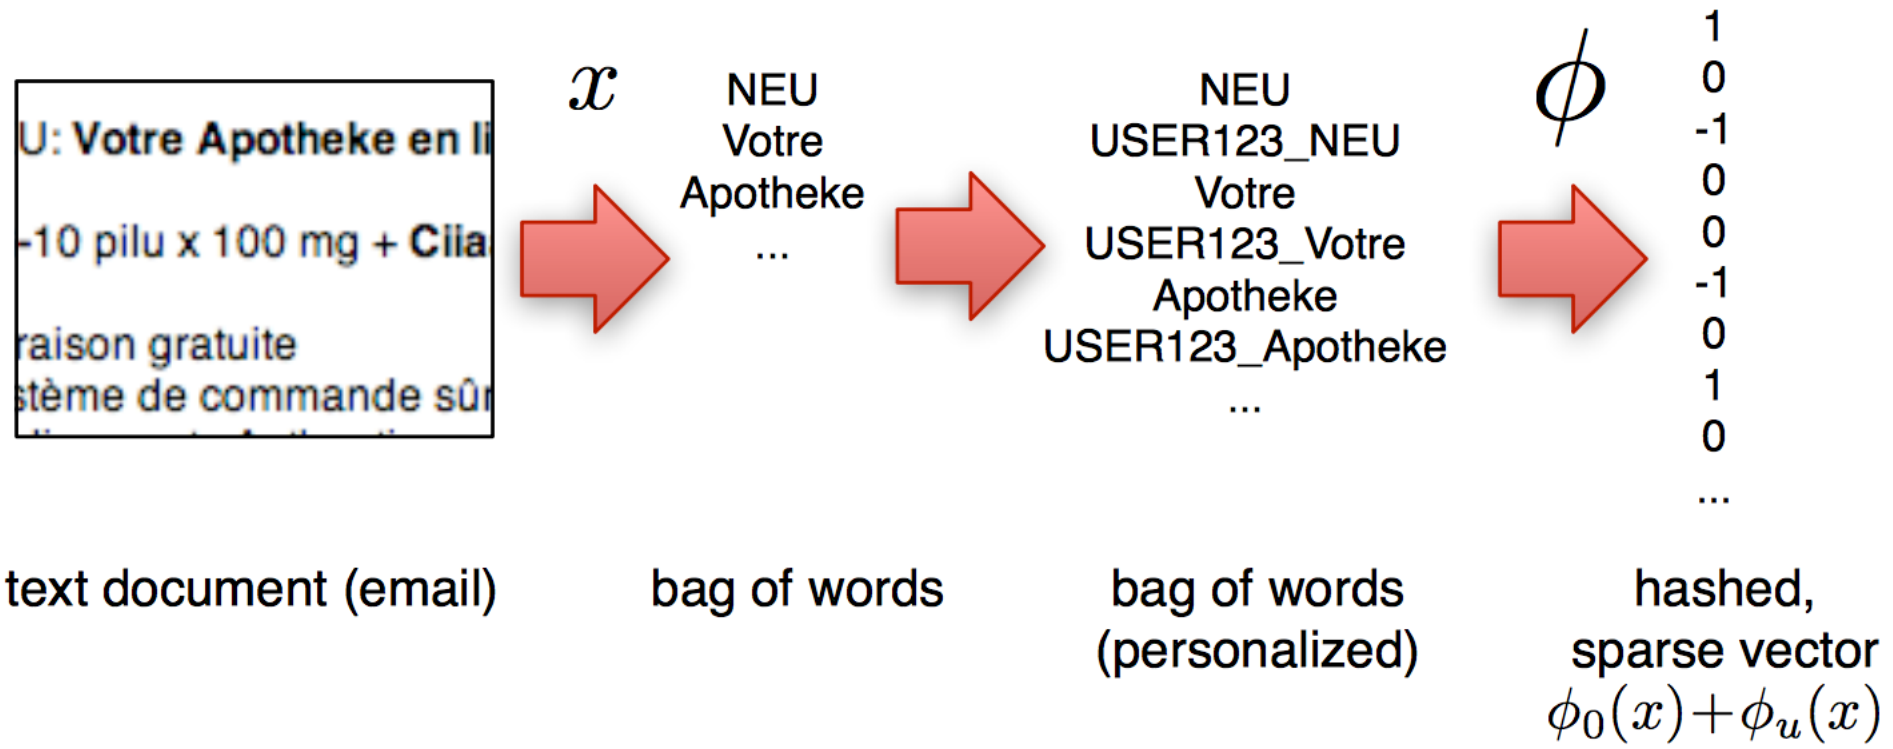

Хэширование в детекции спама

- Хэшированные 16 трлн признаков дают существенный прирост качества
- Хэширование перестает влиять на качество не персональной модели

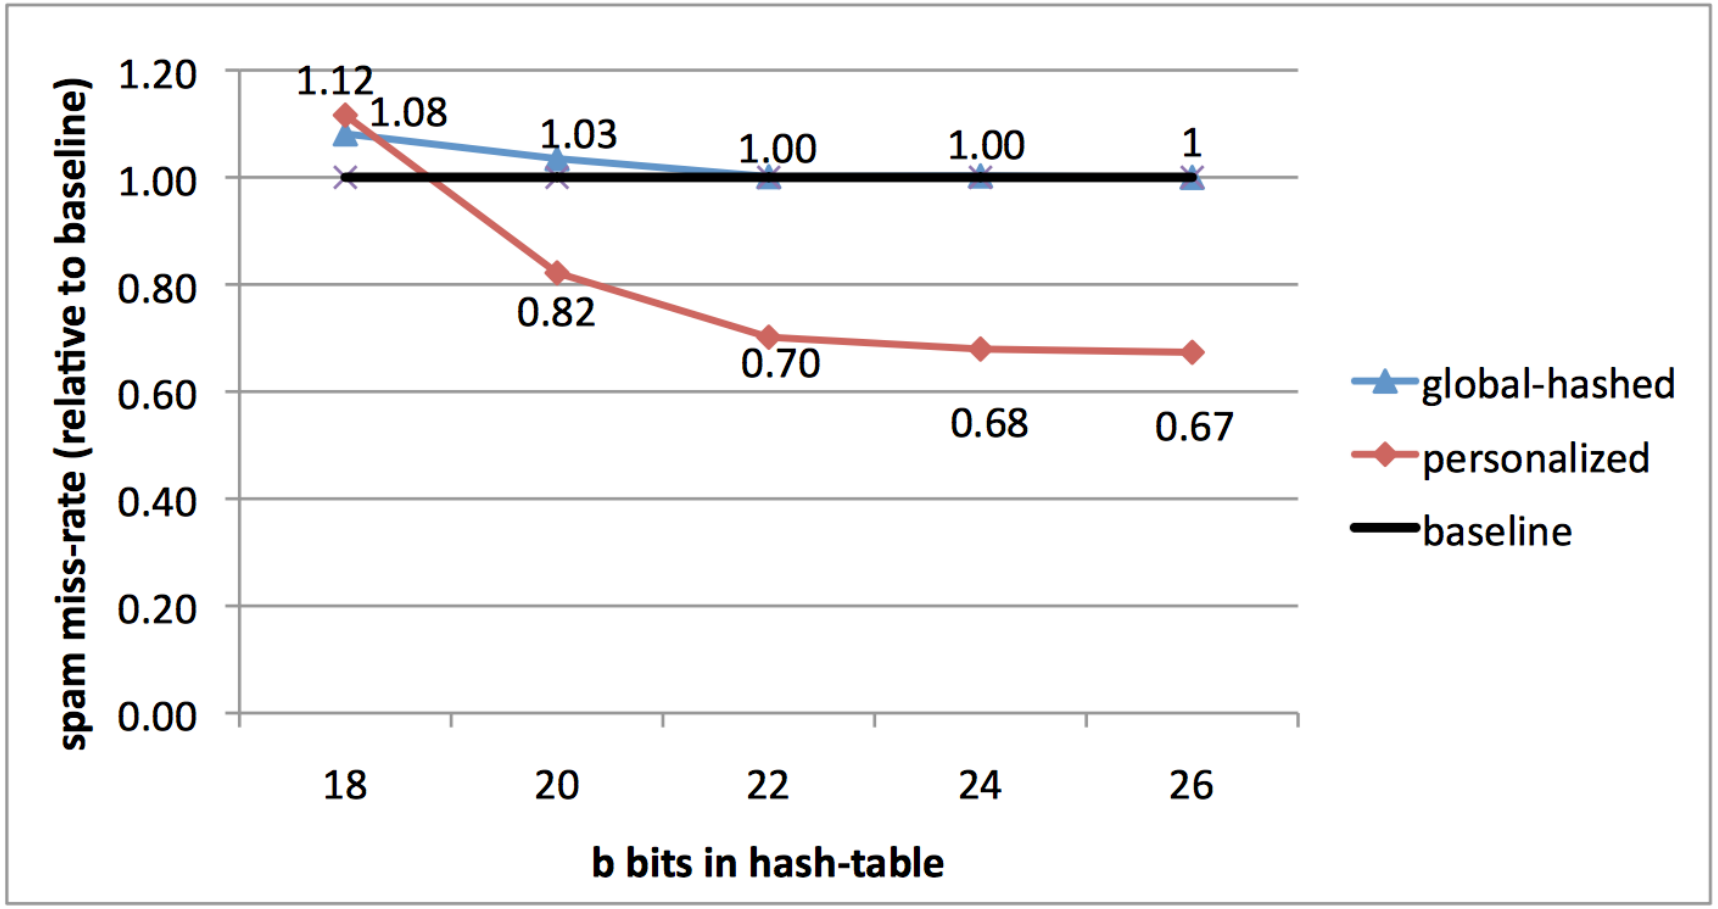

Хэширование в детекции спама

- Хорошо работает даже на пользователях, которых не было в обучении!
- Гипотеза: все «локальные» зависимости были учтены новыми признаками, «глобальные» зависимости стали более универсальными

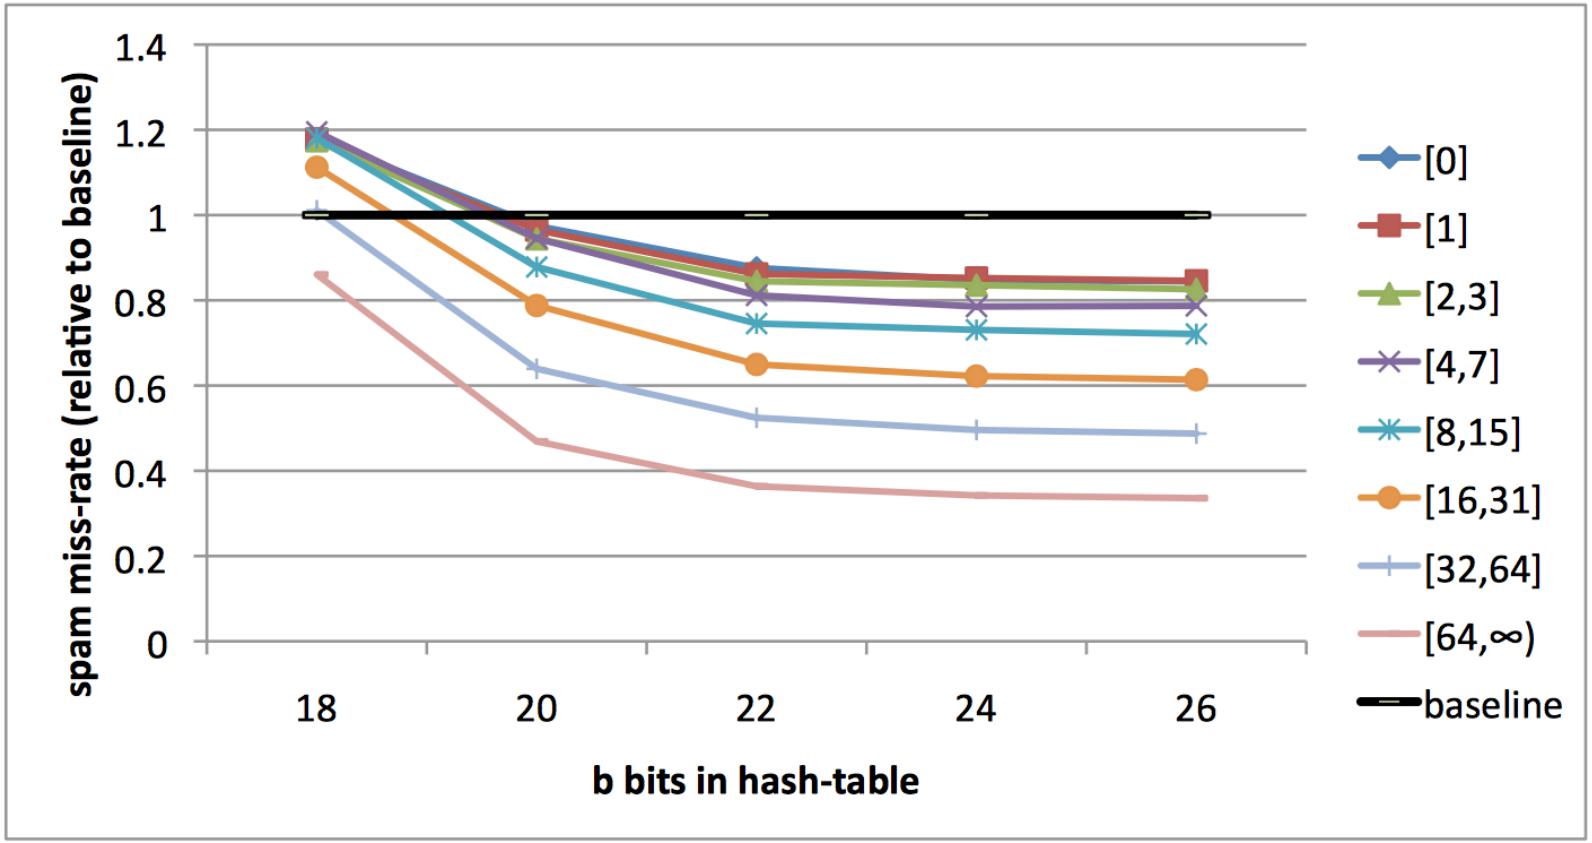

Количество писем пользователя в обучении

Как можно распараллелить работу VW

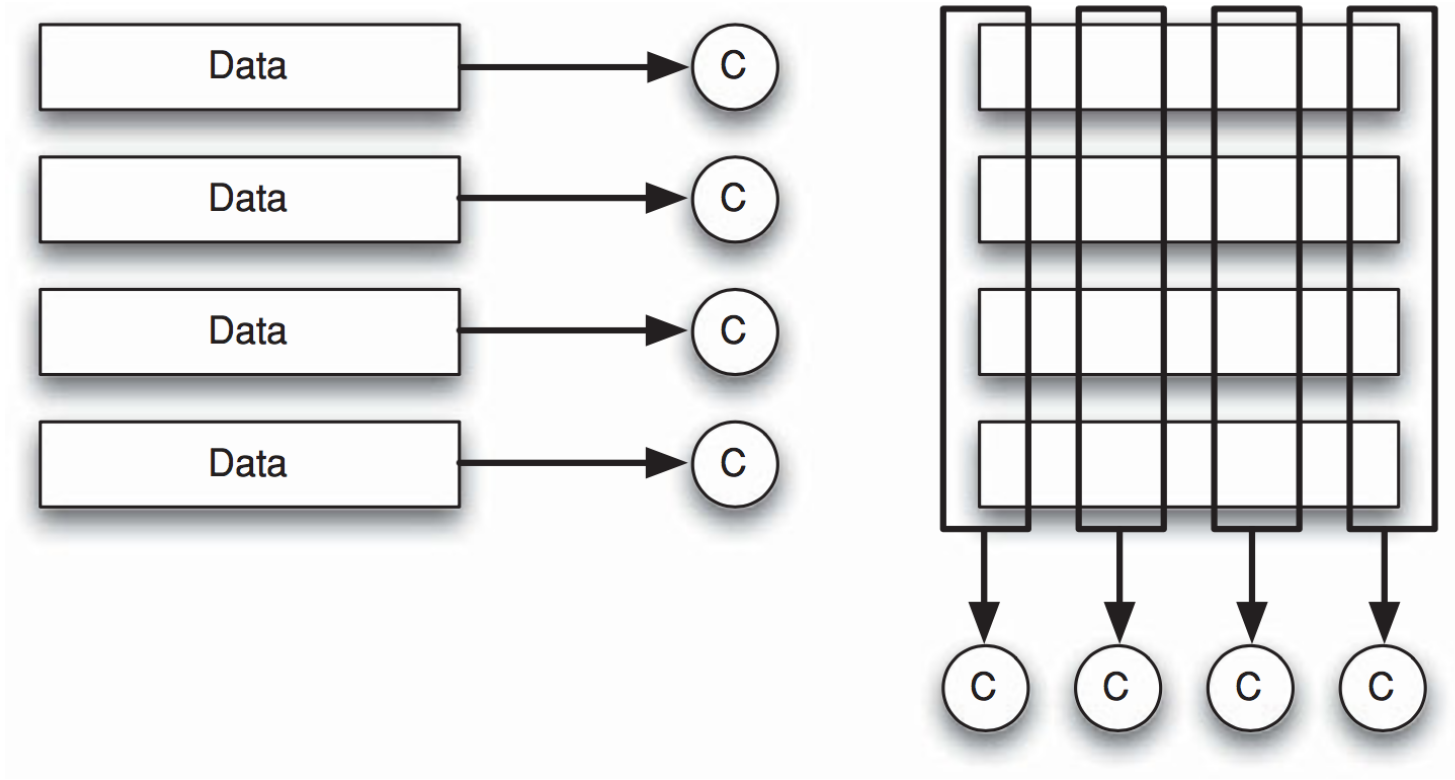

Делим объекты

Делим признаки

http://www.cambridge.org/catalogue/catalogue.asp?isbn=1139210408

Делим признаки на многоядерной машине

- Нужно сделать шаг:

$$w_i = w_{i-1} - \gamma_i x_i (x_i^T w_{i-1} - y_i)$$

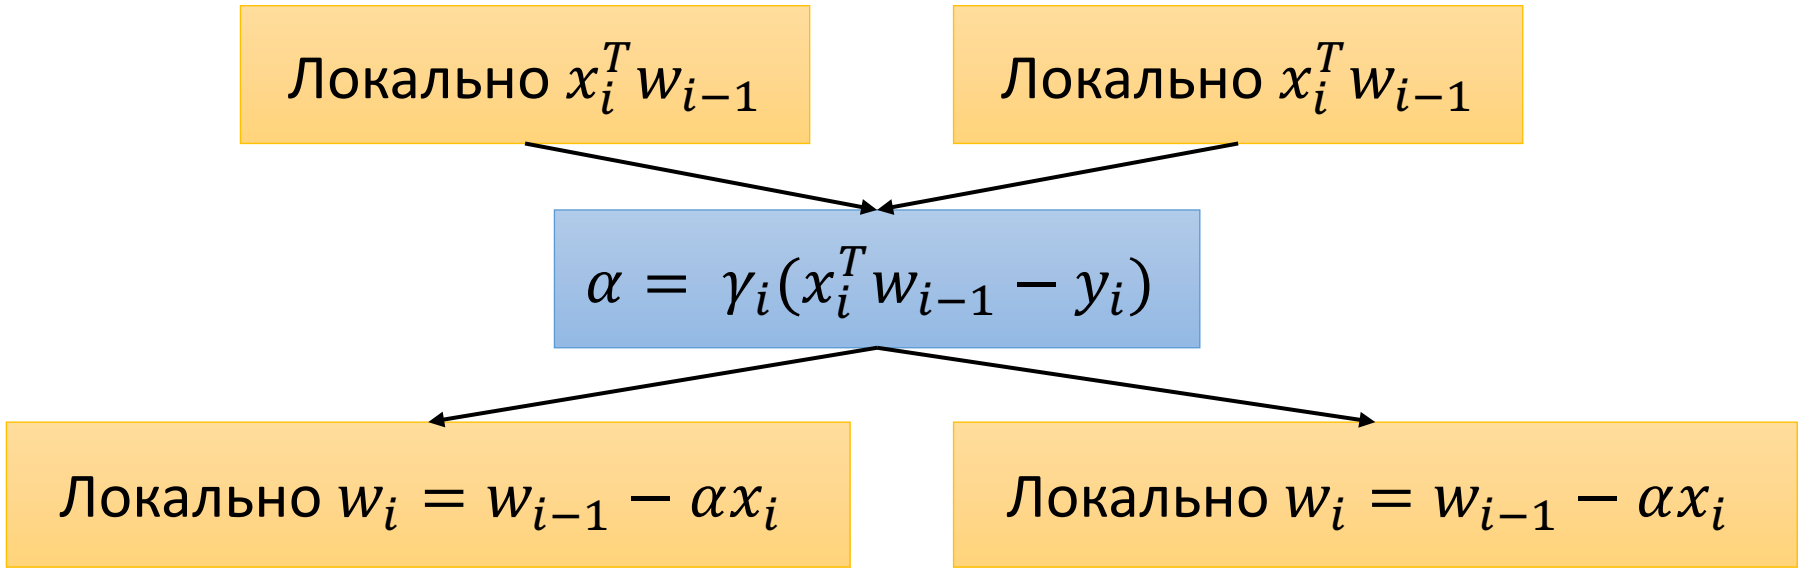

- Результат аналогичен однопоточному варианту
- На 4 ядрах дает ускорение в 3 раза, дальше слабо масштабируется

Делим признаки на много машин

- Нужно сделать шаг:

$$w_i = w_{i-1} - \gamma_i x_i (x_i^T w_{i-1} - y_i)$$

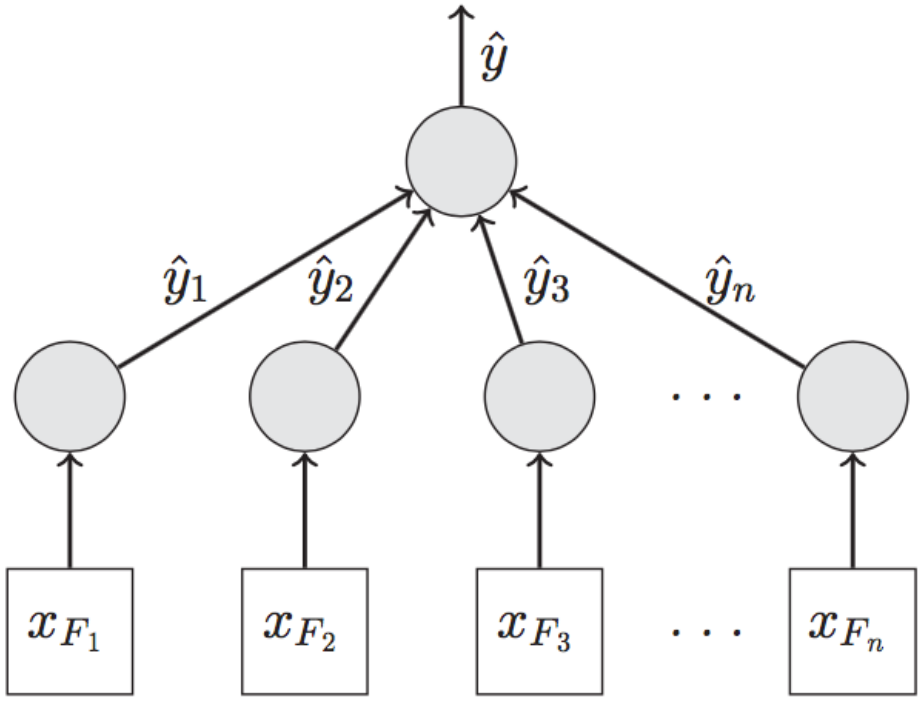

- На каждой машине учится модель, которая использует только свою часть признаков.
- Предсказания пересылаются на мастер машину, которая учит линейную модель, итоговая модель – линейная.
- Отличается от back-propagation, нет пересылки градиентов, модели учатся независимо.

Делим признаки на много машин – go deeper!

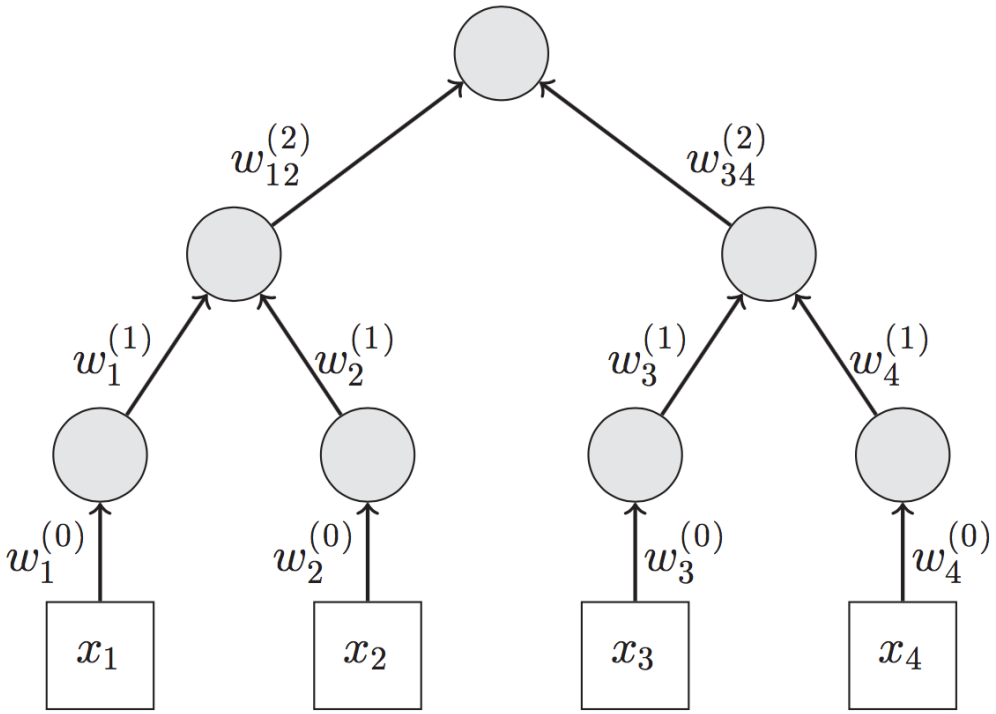

- По выразительной способности между Наивным Байесом и линейными моделями.
- Чем больше слоев, тем более выразительная модель, но больше задержка предсказания. Нужно искать баланс глубины и скорости.
- Не масштабируется линейно, время обмена больше времени вычисления.
- В экспериментах может проигрывать линейной модели по качеству.

Надо делить объекты на много машин!

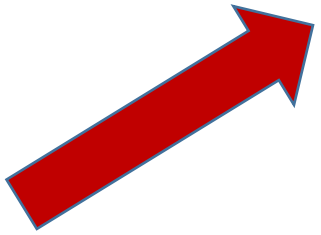

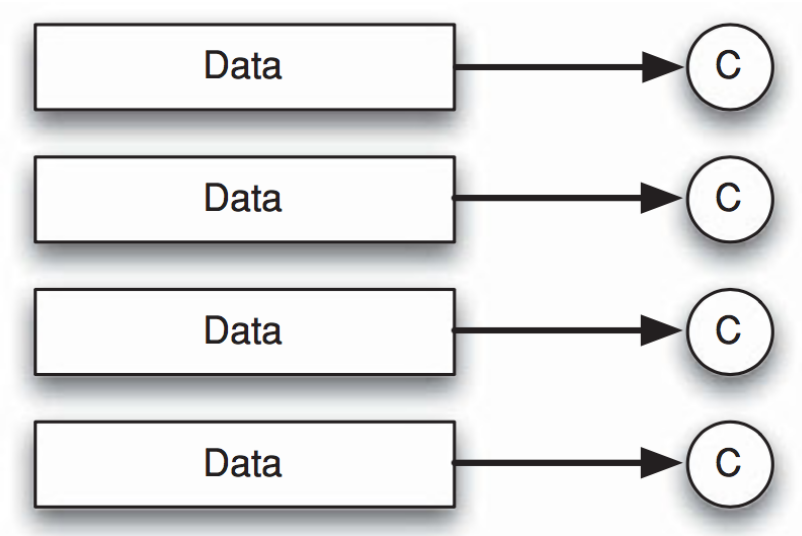

Делим объекты

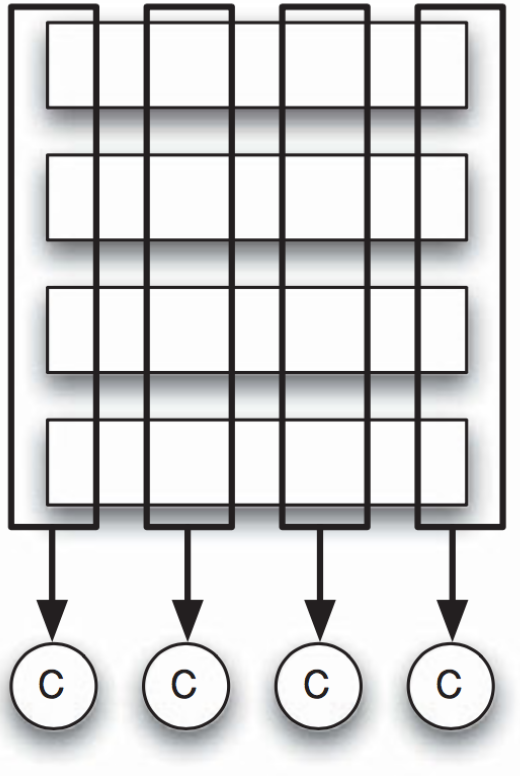

Делим признаки

Поможет Hadoop

- **Hadoop** – проект Apache для распределенных вычислений
- **Hadoop YARN** – планировщик задач и система для управления ресурсами кластера
- **Hadoop MapReduce** – система для вычислений в парадигме Map-Reduce
- **HDFS** – распределенная файловая система Hadoop

Особенности HDFS:

- Файлы хранятся **блоками** на разных машинах
- Каждый **блок дублируется** на нескольких разных машинах (replication factor)
- Информация о соответствии **путь файла → его блоки** хранится на специальной машине **Name Node** в RAM

Парадигма Map-Reduce на примере Word Count

Шаг Map:

(K1, V1) → List(K2, V2)
(#строки, “Deer Bear”) → [(“Deer”, 1), (“Bear”, 1)]

Шаг Shuffle (или Sort):

Shuffle делит данные по **hash(key) % N** на **N** частей
Sort сортирует данные по **key** и делит на **N** частей (по границам **key**)

Шаг Reduce:

(K1, (V1, V2, …)) → List(K3, V3)
(“Bear”, (1, 1)) → [(“Bear”, 2)]

Парадигма Map-Reduce на примере Word Count

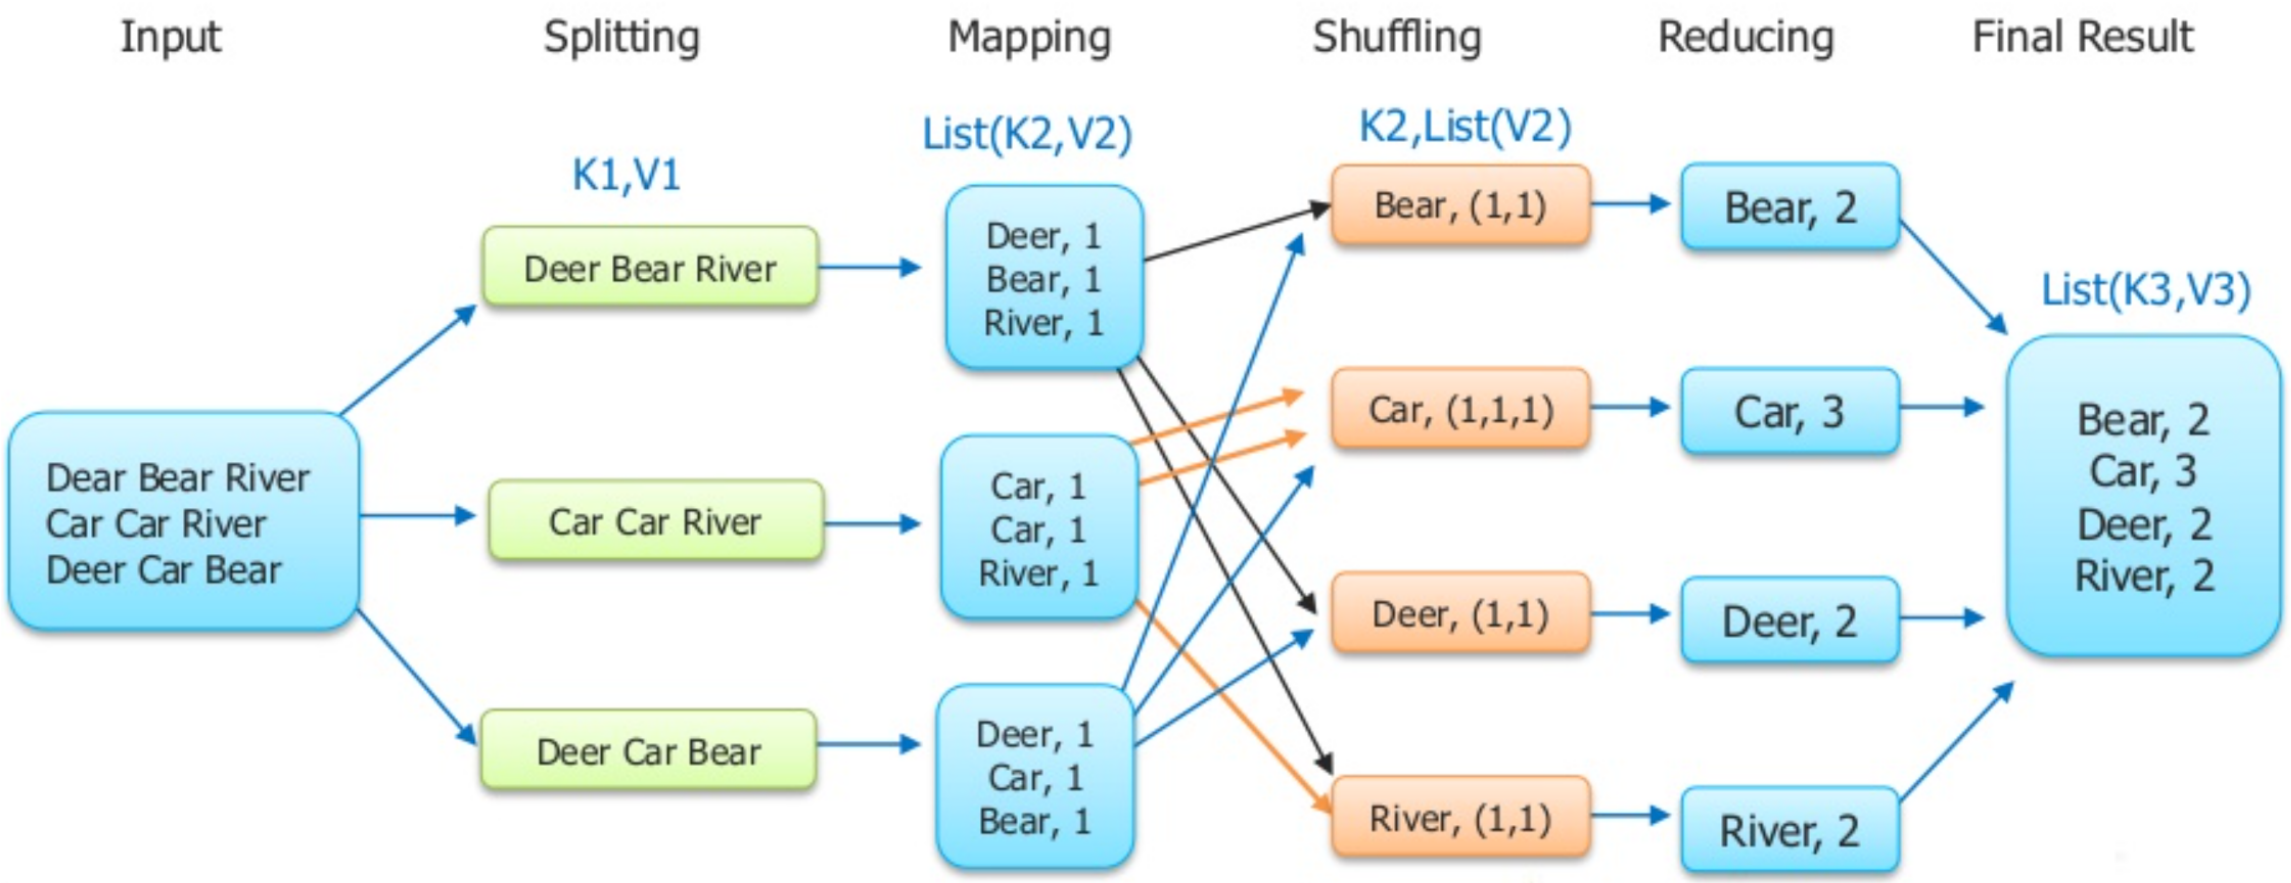

Файл в HDFS

Разбиение блоков для Map-задач

Пересылка по сети по **hash(key) % N**, N – кол-во Reduce-задач

Файл в HDFS

AllReduce в VW

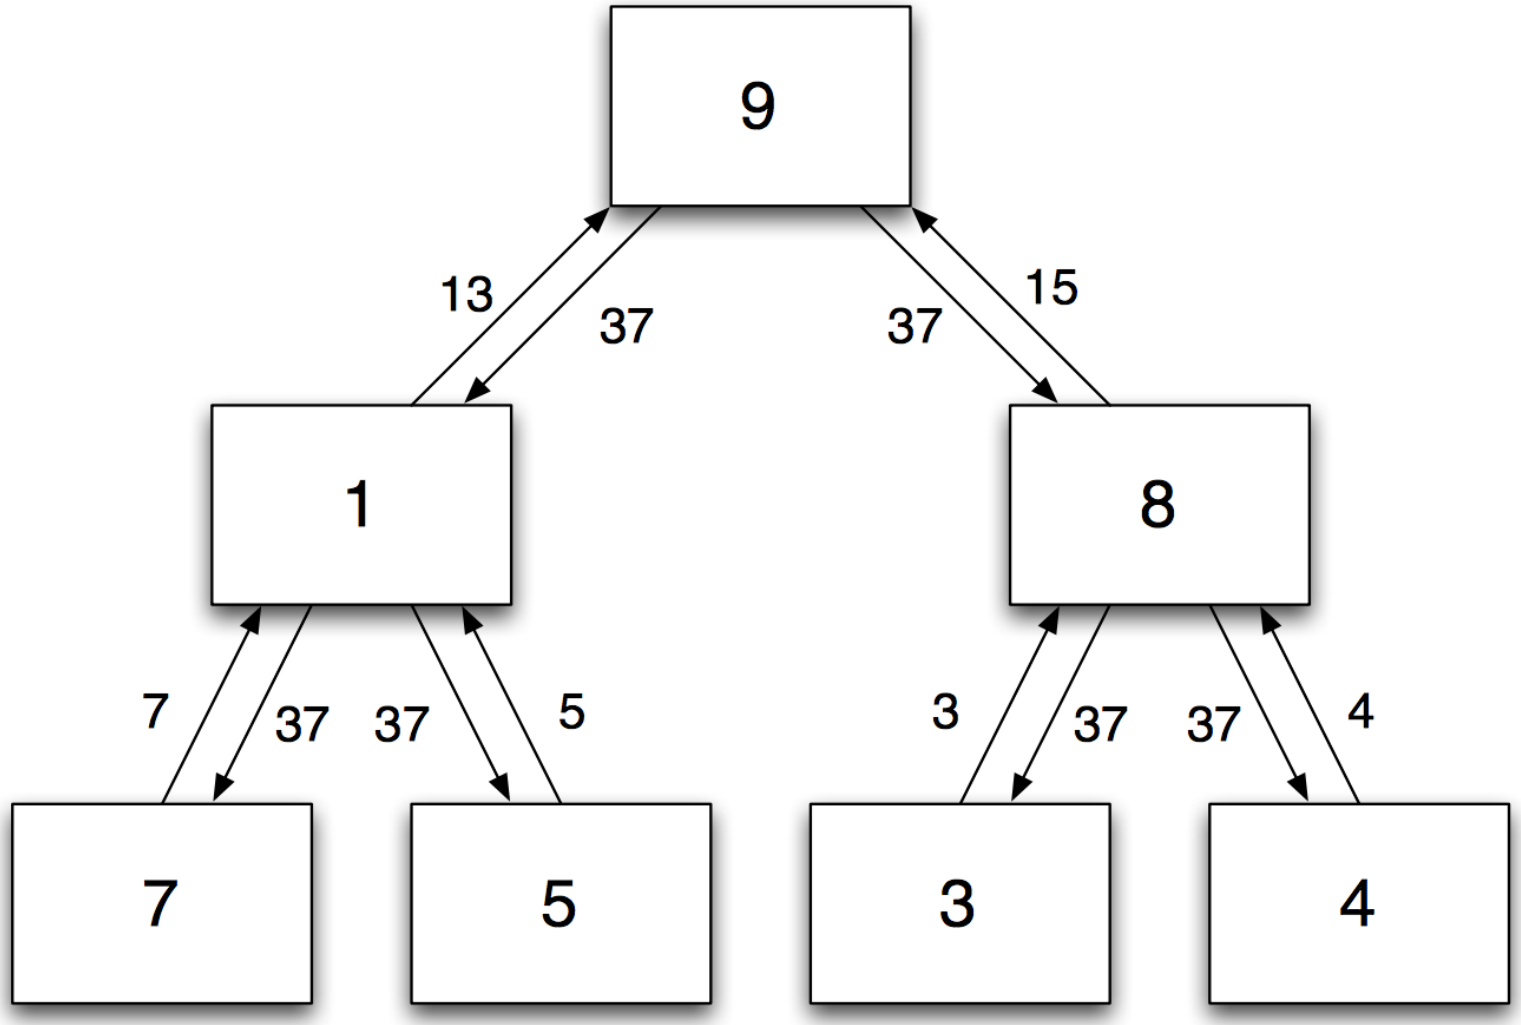

- Каждая машина считает вектор (градиент или веса) по своим объектам
- На каждой машине хочется получить сумму этих векторов от всех машин

https://arxiv.org/pdf/1110.4198.pdf

Конвейеризация в AllReduce

- Не надо передавать весь вектор целиком и ждать, когда мастер машина посчитает сумму.
- Будем отправлять вектор поэлементно (или пачками) и по ходу получать обновленные значения.

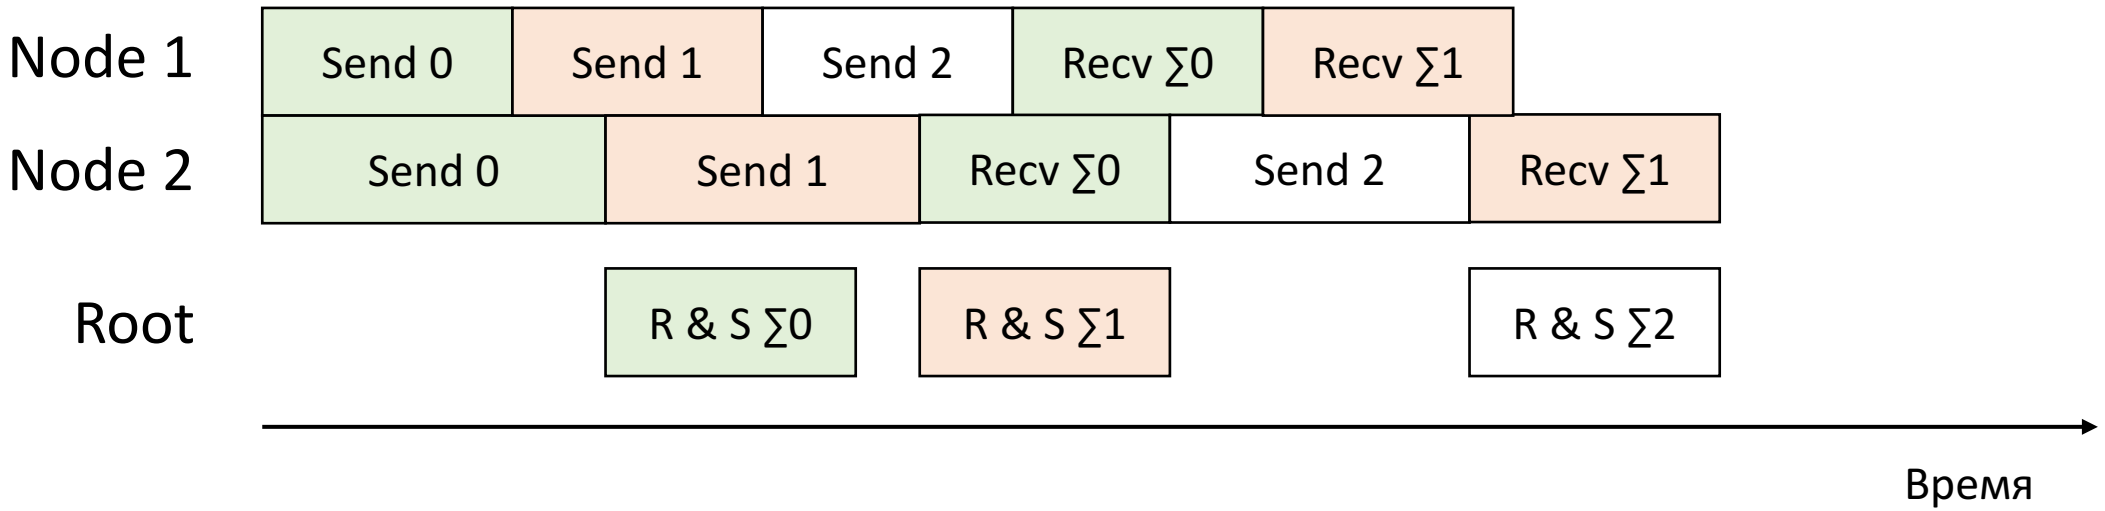

Гибридная схема работы распределенного VW

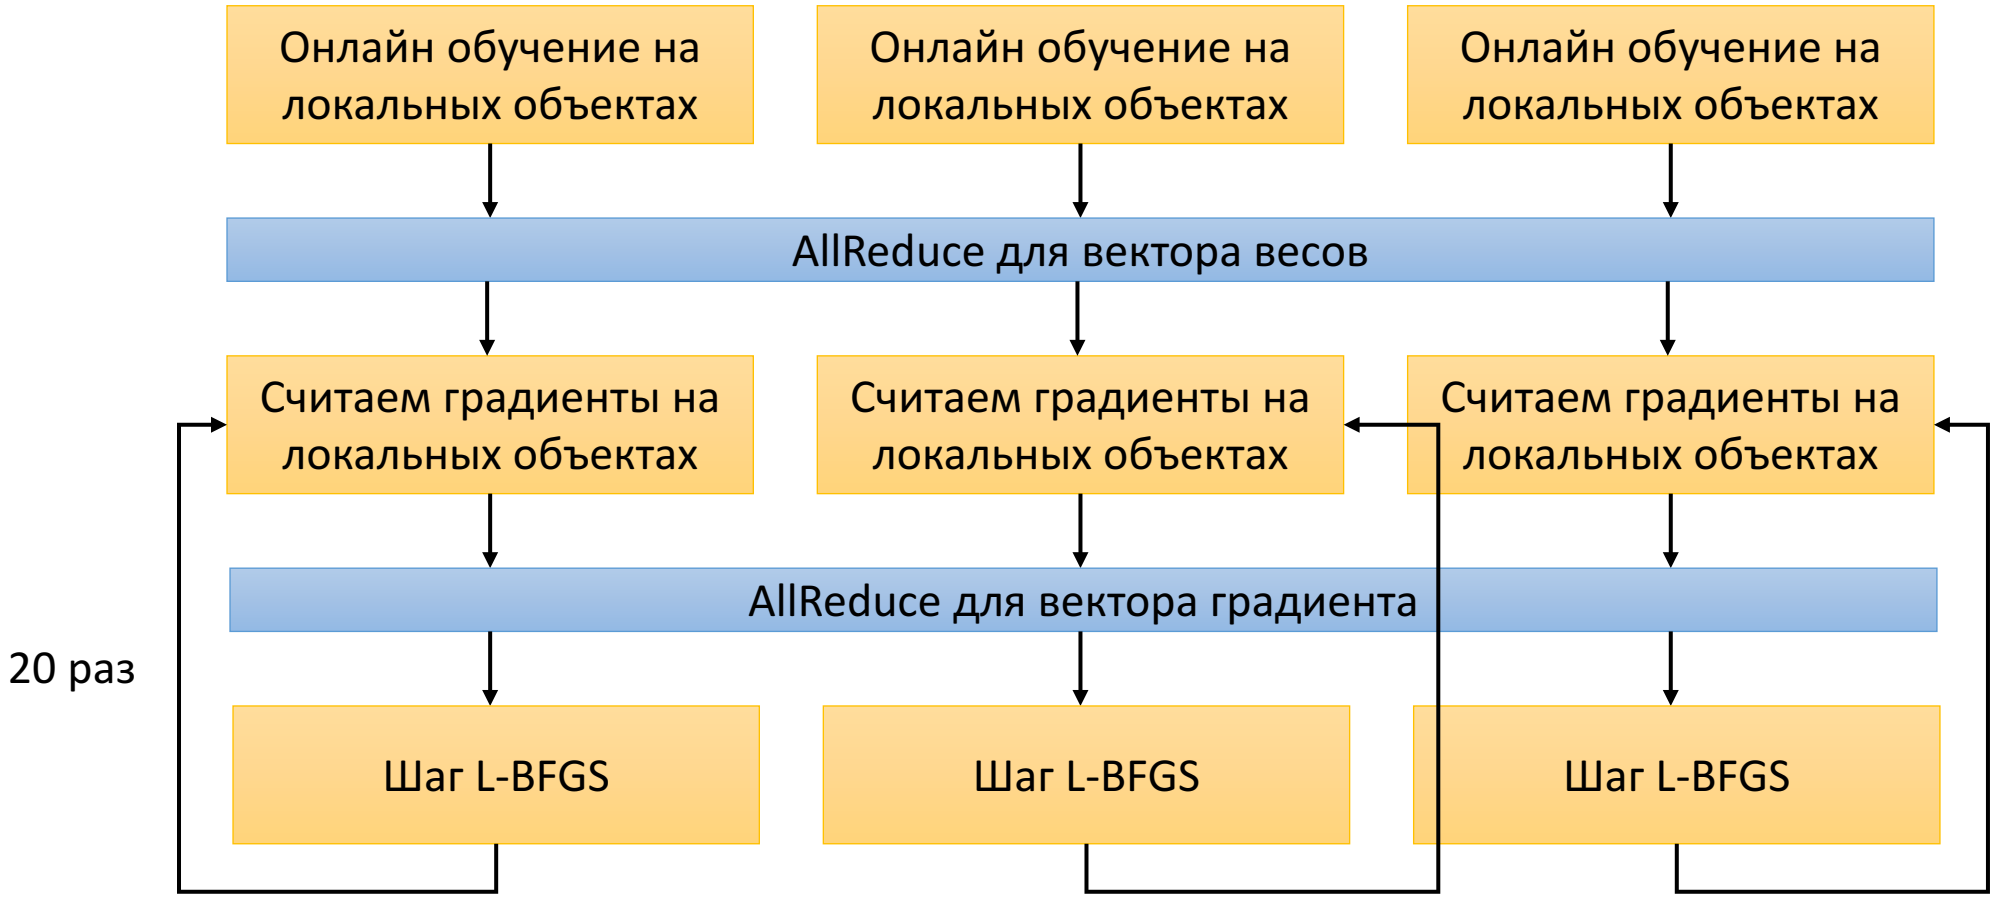

http://people.cs.umass.edu/~mcgregor/stocworkshop/langford.pdf

https://arxiv.org/pdf/1110.4198.pdf

Онлайн обучение на локальных объектах

- Map-задачи в Hadoop
- SGD algorithm using adaptive gradient update:

Require: Invariance update function s
(see Karampatziakis and Langford, 2011)
$\mathbf{w} = \mathbf{0}$, $\mathbf{G} = \mathbf{I}$
for all $(\mathbf{x}, y)$ in training set **do**
$\mathbf{g} \leftarrow \nabla_{\mathbf{w}} \ell(\mathbf{w}^\top \mathbf{x}; y)$
$\mathbf{w} \leftarrow \mathbf{w} - s(\mathbf{w}, \mathbf{x}, y)\mathbf{G}^{-1/2}\mathbf{g}$
$G_{jj} \leftarrow G_{jj} + g_j^2$ for all $j = 1, \ldots, d$
end for

AllReduce для вектора весов

- Пусть у нас m машин, тогда средний вектор весов будем считать так:

$$\bar{\mathbf{w}} = \left(\sum_{k=1}^{m} \mathbf{G}^k \right)^{-1} \left(\sum_{k=1}^{m} \mathbf{G}^k \mathbf{w}^k \right)$$

- G^k – диагональные матрицы, диагональ такого же размера как w^k
- Две операции AllReduce. Работает быстрее агрегации при помощи Map-Reduce:

	Full size	10% sample
MapReduce	1690	1322
AllReduce	670	59

Градиентный спуск

Gradient descent update:

$$\mathbf{w}_{t+1} = \mathbf{w}_t - \eta \nabla f(\mathbf{w}_t)$$

gradient

$$\mathbf{g}_t = \nabla f(\mathbf{w}_t)$$

Equivalently:

- approximate

$$f(\mathbf{w}) \approx f(\mathbf{w}_t) + \mathbf{g}_t^\top (\mathbf{w}_t - \mathbf{w}) + \frac{1}{2\eta} \|\mathbf{w}_t - \mathbf{w}\|^2$$

- optimize approximation:

$$\mathbf{w}_{t+1} = \operatorname*{argmin}_{\mathbf{w}} \left(f(\mathbf{w}_t) + \mathbf{g}_t^\top (\mathbf{w}_t - \mathbf{w}) + \frac{1}{2\eta} \|\mathbf{w}_t - \mathbf{w}\|^2 \right)$$

Can we replace quadratic term by a tighter approximation?

https://github.com/JohnLangford/vowpal_wabbit/wiki/L-BFGS.pdf

http://aria42.com/blog/2014/12/understanding-lbfgs

Метод Ньютона

Hessian

$$\mathbf{H}_t = \nabla^2 f(\mathbf{w}_t)$$

Better approximation

$$f(\mathbf{w}) \approx f(\mathbf{w}_t) + \mathbf{g}_t^\top (\mathbf{w}_t - \mathbf{w}) + \frac{1}{2}(\mathbf{w}_t - \mathbf{w})^\top \mathbf{H}_t (\mathbf{w}_t - \mathbf{w})$$

Update:

$$\mathbf{w}_{t+1} = \mathbf{w}_t - \mathbf{H}_t^{-1} \mathbf{g}_t$$

Problem: Hessian can be too big (matrix of size *dxd*)

https://github.com/JohnLangford/vowpal_wabbit/wiki/L-BFGS.pdf

http://aria42.com/blog/2014/12/understanding-lbfgs

L-BFGS

Instead of the Newton update

$$\mathbf{w}_{t+1} = \mathbf{w}_t - \mathbf{H}_t^{-1}\mathbf{g}_t$$

Perform a ***quasi-Newton*** update:

$$\mathbf{w}_{t+1} = \mathbf{w}_t - \eta_t \mathbf{K}_t \mathbf{g}_t$$

where: $\mathbf{K}_t$ is a low-rank approximation of $\mathbf{H}_t^{-1}$

η_t is obtained by line search

- rank m specified by user (default m=15)
- instead of storage d^2, only storage $2dm$ required (update of $\mathbf{K}_t$ also has running time $O(dm)$ per iteration)

https://github.com/JohnLangford/vowpal_wabbit/wiki/L-BFGS.pdf

http://aria42.com/blog/2014/12/understanding-lbfgs

L-BFGS в VW

--bfgs

turn on LBFGS optimization

--l2 0.0

L2 regularization coefficient

--mem 15

rank of the inverse Hessian approximation

--termination 0.001

termination threshold for the
relative loss decrease

VW выводит ошибку модели

- Стандартный путь: обучение на train, качество на test

- При одном проходе по данным достаточно **progressive validation**
  - Для каждого нового объекта считается ошибка до обновления параметров
  - Выводится средняя ошибка по таким объектам
  - Доказано, что приближает ошибку на тесте

- При втором проходе по данным не будет иметь смысла
  - VW сам откладывает 10% данных в holdout, если указали больше одного прохода по данным (эпохи)
  - Можно отключить при помощи --holdout_off

http://cilvr.cs.nyu.edu/diglib/lsml/lecture01-online-linear.pdf

http://hunch.net/~jl/projects/prediction_bounds/progressive_validation/coltfinal.pdf

Задача предсказания кликов по рекламе

- **2.1T** разреженных признаков
- **17B** примеров
- **16M** параметров (24 hash bits)
- **1K** машин
- Оптимальный линейный классификатор за **70 минут**

	1%	10%	100%
auROC	0.8178	0.8301	0.8344
auPRC	0.4505	0.4753	0.4856
NLL	0.2654	0.2582	0.2554

Сэмплирование ухудшает качество – нужно учиться на всех данных!

http://fastml.com/vowpal-wabbit-eats-big-data-from-the-criteo-competition-for-breakfast/

http://people.cs.umass.edu/~mcgregor/stocworkshop/langford.pdf

Задача предсказания кликов по рекламе

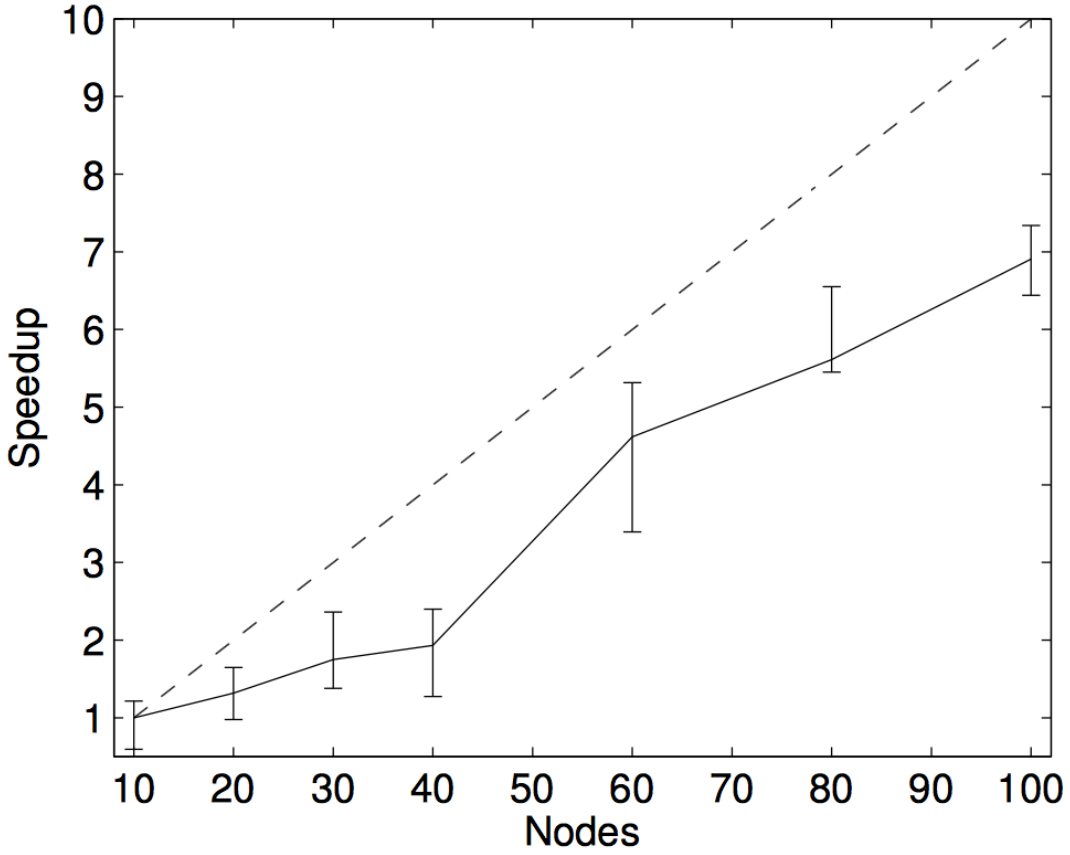

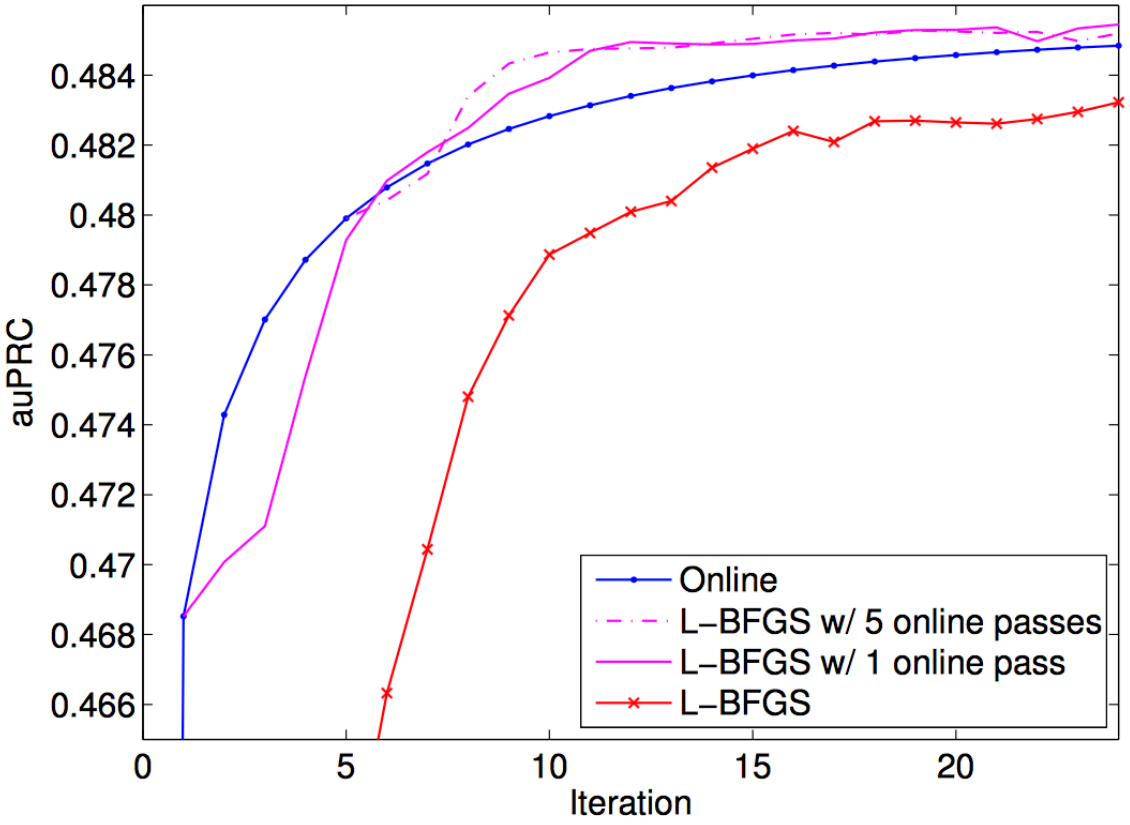

https://arxiv.org/pdf/1110.4198.pdf

Репозиторий курса

https://github.com/ZEMUSHKA/lsml_hse

или

http://bit.ly/2oquZdc

Ссылки

- A Reliable Effective Terascale Linear Learning System https://arxiv.org/pdf/1110.4198.pdf
- http://cilvr.cs.nyu.edu/diglib/lsml/lecture01-online-linear.pdf
- https://github.com/JohnLangford/vowpal_wabbit/wiki/Tutorial
- http://www.zinkov.com/posts/2013-08-13-vowpal-tutorial/
- http://mlwave.com/predicting-click-through-rates-with-online-machine-learning/
- http://aria42.com/blog/2014/12/understanding-lbfgs